Esteganografía de metadatos en audio mediante enmascaramiento con eco

Marco Zolla Salazar, Marcelo Mata Solano y Luis Diego Martinez Jimenez

***Abstract*—This paper presents a system that hides song metadata in audio files by echo hiding. Each window carries one bit as an echo applied by convolution with overlap-add. The decoder classifies windows with the autocorrelation of the cepstrum and corrects bit errors by a majority vote across the repeated copies. The defaults ($750\,\mu s$ and $1500\,\mu s$ delays, $30\,\%$ attenuation, $26.73\,\mathrm{bit/s}$) recover $95.7\,\%$ to $98.3\,\%$ of the bits in $20\,s$ excerpts of three recordings, with wideband perceptual evaluation of speech quality (PESQ) scores of 3.80 to 4.15. Quality falls with echo amplitude and trades off against recovery. Voting raises the fields recovered at a $5\,\%$ bit error rate from 0.15 to 5.15 of seven on average and recovers all three encoded fields in $60\,s$ of real music, but needs at least three copies and does not correct dropped or inserted bits. Unencoded files produced no false metadata.**

***Palabras clave*—Acoustic signal processing, audio coding, cepstral analysis, error correction codes, steganography.**

I. Introducción

La esteganografía en señales de audio consiste en ocultar información digital dentro de una señal portadora acústica sin alterar de manera perceptible su reproducción, lo que resulta de gran utilidad en el almacenamiento de metadatos de canciones, el control de derechos de autor y la autenticación de grabaciones [1], [2].

Entre las técnicas clásicas reportadas en el estado del arte destacan la sustitución del bit menos significativo, la codificación de fase, el espectro disperso y el enmascaramiento con eco [1], [2]. El enmascaramiento con eco, introducido originalmente por Gruhl, Lu y Bender [3], aprovecha la propiedad psicoacústica según la cual una réplica atenuada con un retardo del orden de un milisegundo no se percibe como un eco separado, sino como una ligera resonancia espectral enmascarada por la señal principal.

El resto de este artículo se organiza de la siguiente manera. En la Sección II se desarrolla el marco teórico del eco como sistema lineal e invariante en el tiempo (LTI) y del cepstro, y en la Sección III, la solución propuesta. En la Sección IV se presentan y discuten los resultados experimentales. Finalmente, en la Sección V se exponen las conclusiones y las recomendaciones para trabajos futuros.

II. Marco teórico

II-A. Enmascaramiento con eco mediante sistemas LTI

El enmascaramiento con eco permite representar información binaria mediante la adición de una réplica atenuada y retardada de una señal de audio. Para cada bit $b \in \{0, 1\}$ se define un sistema LTI cuya respuesta al impulso es

$$h_b[n] = \delta[n] + a_b \delta[n - d_b], \tag{1}$$

donde a_b representa la amplitud del eco, igual a la atenuación configurada expresada como fracción, y d_b el retardo en muestras asociado al símbolo binario. La salida del sistema se obtiene mediante la convolución discreta:

$$y_b[n] = x[n] * h_b[n] = x[n] + a_b x[n - d_b]. \tag{2}$$

Para insertar una secuencia de bits, la señal se divide en ventanas de L muestras. Cada ventana se convoluciona con la respuesta al impulso correspondiente al bit que se desea codificar. Debido a que la convolución genera una cola de d_b muestras adicionales, las contribuciones de ventanas consecutivas se acumulan mediante el método de solapamiento y suma, conservando la continuidad de la señal resultante.

II-B. Cepstro y autocorrelación espectral

Cuando una ventana de audio $x_k(n)$ atraviesa el filtro de eco h_b asociado al bit b, su salida $y_k(n)$ tiene transformada de Fourier de tiempo discreto $Y_k(\omega) = X_k(\omega)\left(1 + a_b e^{-j\omega d_b}\right)$. Para separar multiplicativamente la respuesta del eco respecto a la señal portadora, se emplea el cepstro $c(n)$, definido en la Ecuación (3) a partir de la transformada de Fourier $\mathcal{F}$ y su inversa $\mathcal{F}^{-1}$ [3]:

$$c(n) = \mathcal{F}^{-1}\left\{\ln\left(\mathcal{F}\{y_k(n)\}\right)\right\}. \tag{3}$$

Para $a_b < 1$, la expansión en serie de Taylor $\ln(1 + a_b e^{-j\omega d_b}) = \sum_{m=1}^{\infty} \frac{(-1)^{m+1}}{m} a_b^m e^{-j\omega m d_b}$ muestra que el eco induce en el dominio de la quefrencia n un tren de impulsos ubicado en los múltiplos del retardo d_b, donde el término dominante en $n = d_b$ posee amplitud proporcional a a_b.

Para reforzar dicho impulso, Gruhl *et al.* [3] proponen evaluar la convolución del cepstro consigo mismo. Aplicando el teorema de convolución, la autocorrelación del cepstro $R_{cc}(n)$ se calcula directamente en el dominio espectral según la Ecuación (4):

$$R_{cc}(n) = c_r(n) * c_r(n) = \mathcal{F}^{-1}\left\{\left(\ln\left|\mathcal{F}\{\hat{v}_k(n)\}\right|\right)^2\right\}. \tag{4}$$

Aquí $c_r(n) = \mathcal{F}^{-1}\{\ln|\mathcal{F}\{\hat{v}_k(n)\}|\}$ es el cepstro real, la parte par de $c(n)$, que conserva los picos en los múltiplos de d_b; por ser par, su convolución consigo mismo es también su autocorrelación, y $\hat{v}_k(n)$ es la ventana recibida, normalizada como se define en la Sección III-B.

M. Zolla Salazar, M. Mata Solano y L. D. Martinez Jimenez están con la Maestría en Ingeniería Electrónica, Instituto Tecnológico de Costa Rica, Costa Rica (correo: mzolla@estudiantec.cr; m.mata.3@estudiantec.cr; diego_mj22@estudiantec.cr).

III. Solución propuesta

La Figura 1 ilustra el sistema completo: el codificador toma los metadatos y los convierte en una secuencia de bits, que repite hasta tener un bit por ventana. Cada una de estas se convoluciona con una de dos posibles respuestas al impulso, dependiendo del valor del bit en la ventana. El decodificador luego clasifica cada ventana con la autocorrelación del cepstro y lee los metadatos de la secuencia de bits, junto con los de una copia obtenida por votación entre las repeticiones.

III-A. Codificador de eco

Se desarrolló un prototipo en Python y una implementación en C++17. El programa lee archivos de audio en formato WAV (*waveform audio file format*) estéreo, con modulación por impulsos codificados (PCM) de 16 bits, permite elegir el canal de inserción y configurar los retardos y las atenuaciones. Los retardos, en microsegundos, se redondean a muestras enteras a $44.1\,\mathrm{kHz}$, y la longitud de ventana es $L = K\,\mathrm{máx}(d_0, d_1)$ con $K = 25$: con los valores por defecto, $d_0 = 33$ y $d_1 = 66$ muestras, $a_b = 0.3$ y $L = 1650$ muestras ($37.4\,\mathrm{ms}$). Cada ventana se procesa mediante convolución explícita con la respuesta al impulso correspondiente al bit, y las contribuciones desplazadas se acumulan mediante solapamiento y suma en un búfer que empieza en ceros; el canal no seleccionado conserva sus muestras originales. Al escribir el WAV, con el mismo formato que el original, se aplica saturación al intervalo de 16 bits y truncamiento hacia cero.

III-B. Subsistema decodificador

El subsistema decodificador recibe el canal seleccionado del archivo PCM de $16\,\mathrm{bits}$ a $f_s = 44.1\,\mathrm{kHz}$ y los retardos configurados t_0 y t_1 en microsegundos, los cuales se convierten a muestras enteras mediante $d_b = \lfloor (t_b f_s + 5 \times 10^5)/10^6 \rfloor$. A partir del mayor retardo se fija la longitud de ventana $L = K\,\mathrm{máx}(d_0, d_1)$ con $K = 25$, segmentando la señal en ventanas contiguas $v_k(n)$.

Las muestras conservan la escala de enteros de 16 bits. En cada ventana $v_k(n)$ se calcula primero su valor eficaz o raíz cuadrática media, $\mathrm{RMS}(v_k)$. Si $\mathrm{RMS}(v_k) \leq 10^{-5}$, es decir, si todas sus muestras son cero, la ventana se declara silenciosa y se etiqueta inmediatamente como carente de eco. En caso contrario, se normaliza mediante $\hat{v}_k(n) = v_k(n)\,\mathrm{RMS}_{\mathrm{ref}}/\mathrm{RMS}(v_k)$ con $\mathrm{RMS}_{\mathrm{ref}} = 1000$, eliminando cualquier dependencia respecto a la amplitud de entrada. Posteriormente, $\hat{v}_k(n)$ se rellena con ceros hasta la siguiente potencia de dos $N = 2^{\lceil \log_2 L \rceil}$ y se evalúa la transformada rápida de Fourier (FFT). Para prevenir singularidades logarítmicas en frecuencias nulas, cada magnitud espectral se acota inferiormente por $\epsilon = 10^{-6}$ antes de evaluar la Ecuación (4) con la transformada inversa rápida de Fourier (IFFT), cuya parte real es $R_{cc}(n)$.

Finalmente, el clasificador evalúa $r_0 = R_{cc}(d_0)$ y $r_1 = R_{cc}(d_1)$. Se usa el valor con signo y no su magnitud, porque los valores negativos que produce la música se confundirían con picos de eco. Si $\mathrm{máx}(r_0, r_1) < U_{\mathrm{eco}}$ con umbral $U_{\mathrm{eco}} = 0.70$, o si r_0 y r_1 difieren en menos de 10^{-9} relativo, la ventana individual se clasifica como ventana sin eco; de lo contrario, se asigna el bit 0 cuando $r_0 > r_1$ y el bit 1 cuando $r_1 > r_0$. A nivel de señal completa, como filtro de actividad, si menos del $25\,\%$ de las ventanas no silenciosas tienen eco, el archivo se reconoce como no codificado y se devuelve una secuencia vacía. En archivos codificados, se recorta la cola final de cuatro o más ventanas sin eco, y cada ventana restante con sonido entrega un bit al intérprete de trama, aunque se haya clasificado sin eco: 0 si $r_0 \geq r_1$ y 1 en otro caso.

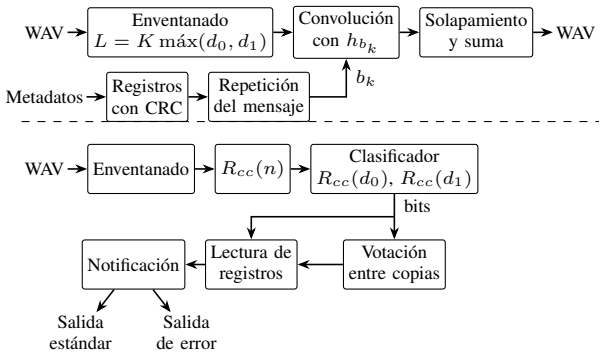


Figura 1. Diagrama del sistema: codificador (arriba) y decodificador (abajo); CRC es la verificación de redundancia cíclica de cada registro y b_k, el bit de la ventana k.

III-C. Trama de metadatos y votación

Cada metadato entrante se convierte en un registro con un preámbulo (`0xB2`), su categoría y su longitud, de un byte cada uno, y su texto en el formato de transformación de Unicode de 8 bits (UTF-8) [4], de 1 a 255 bytes, y una verificación de redundancia cíclica (CRC) de 16 bits, sobre categoría, longitud y texto, que permite detectar si algún bit del registro llegó mal. La CRC usa el polinomio $x^{16} + x^{12} + x^5 + 1$, con valor inicial `0xFFFF` y sin reflexión ni operación final [5]. La categoría sigue esta taxonomía, de 1 a 7: título, artista, autor, álbum, año, artista invitado y productor. Los registros se concatenan en orden de categoría, con el bit más significativo de cada byte primero, y forman el mensaje. Cada ventana de 1650 muestras lleva un bit de información, y el mensaje se repite hasta ocupar todas las ventanas. Las ventanas con todas sus muestras en cero no llevan bit, porque siguen en cero después de agregarles el eco; el codificador las salta, como proponen Gruhl *et al.* [3].

El decodificador tolera un bit errado en el preámbulo cuando está justo donde se espera que empiece un registro, al inicio o justo después de uno leído bien; lo mismo no es cierto para otras posiciones, ya que se podría confundir con un byte de datos. Si la CRC coincide, el registro es válido cuando su categoría está entre 1 y 7 y su texto es UTF-8 correcto, y desconocido en otro caso; si no coincide y el registro empezaba donde se esperaba con una categoría válida, se considera dañado. Si un registro no es confirmado, la búsqueda sigue desde el bit siguiente en vez de saltar el registro entero: así, si se pierde o se agrega un bit, solo se pierde ese registro y los siguientes se vuelven a encontrar.

Si cada bit se lee mal con probabilidad p, de forma independiente, un registro de m bits llega intacto con probabilidad

$(1-p)^m$: con $p = 5\,\%$, $2.5\,\%$ para un registro de 72 bits y $0.0007\,\%$ para uno de 232. Por eso se agregó un mecanismo de votación para la corrección de errores: las copias repetidas del mensaje se combinan con un código de repetición con decisión por mayoría. Como el mensaje se repite, la secuencia de B bits leída se parece a sí misma desplazada un período P: se prueba cada desplazamiento, de 48 a $\min(\lfloor B/3 \rfloor, 14560)$ bits, y se cuenta cuántos bits coinciden, en bloques de 64 bits que aceptan hasta 4 bits de corrimiento. Como $2P$ y $3P$ también coinciden, se elige el menor desplazamiento a menos de 2 puntos porcentuales del mejor, y se ajusta probando sin tolerancia ese valor y los 8 siguientes; si ni el mejor llega al $75\,\%$ de bits iguales, no se vota. Superponiendo las copias, cada bit se decide por mayoría; en un empate, o con menos de tres copias, vale la primera. Después, con la copia votada como referencia, se vuelve a buscar el inicio de cada copia, hasta 4 bits antes o después, y se vota otra vez. Este proceso se hace dos veces. La copia votada se lee igual que la secuencia original, y sus registros válidos se suman a los de la lectura directa.

Por cada categoría con algún registro válido se imprime en la salida estándar su nombre y el texto que más se repite (por ejemplo, «Título: The Entertainer»), y los registros desconocidos o dañados se imprimen en la salida de error con una advertencia, solo si se leyó algún registro válido, para no dar avisos falsos con un audio sin codificar.

IV. Resultados

IV-A. *Calidad de la señal codificada*

Los fragmentos de prueba, de 20 s, son la *Primavera* de Vivaldi (clásica de cuerdas), *The Entertainer* de Joplin (*ragtime* en piano), una grabación de *jazz* para flauta y saxofón y una pieza electrónica sintética generada con una semilla fija; las fuentes y los cortes están en el repositorio. Para medir la calidad se codificó cada fragmento con el programa final, con tres metadatos repetidos en todas las ventanas del canal izquierdo, y se comparó con el original. La calidad perceptual se midió con la evaluación perceptual de la calidad de la voz (PESQ) en su versión de banda ancha [6], [7], que estima la nota de opinión media de un oyente en una escala de 1 a 5, sobre las dos señales remuestreadas a 16 kHz. PESQ está diseñada para voz en la banda de 50 Hz a 7000 Hz: no evalúa el contenido más agudo, y su detector de actividad rechaza la pieza electrónica sintética, que por eso no tiene nota. También se midió la relación señal a ruido (SNR), tomando como ruido la diferencia entre la señal codificada y la original.

La Figura 2 muestra la nota PESQ en función de la atenuación, con los retardos por defecto. La calidad baja de forma sostenida al aumentar la amplitud del eco: de 4.49–4.54 con $10\,\%$ a 3.10–3.60 con $50\,\%$. Con los valores por defecto ($a = a_0 = a_1 = 0.3$), la nota es 4.15 en la clásica, 4.08 en el *ragtime* y 3.80 en el *jazz*, el género más sensible al eco. La SNR coincide en todas las piezas con $-20\log_{10} a$ (10.46 dB con $a = 0.3$), porque con todas las ventanas codificadas el eco es una copia de la señal con potencia a^2 veces la original; por eso no distingue géneros y PESQ sí.

Al relacionar la calidad con la tasa de recuperación de bits del mismo barrido, el coeficiente de correlación de Pearson es

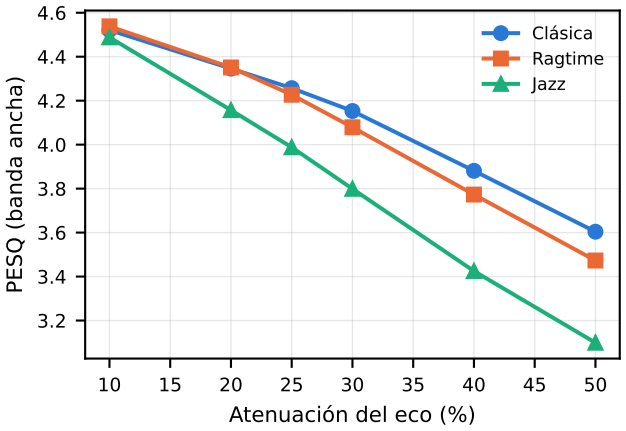


Figura 2. PESQ de banda ancha en función de la atenuación del eco, con retardos de 750 µs y 1500 µs.

-0.76 en 18 puntos. Para la tasa de transferencia se variaron los retardos con $30\,\%$ de atenuación, de modo que la tasa fue de 20.05 bit/s a 53.45 bit/s. Con los tres géneros juntos la correlación es de -0.07, pero por género es de -0.97 en el *jazz*, 0.57 en la clásica y 0.40 en el *ragtime*, con solo cinco puntos cada uno: en el *jazz* la calidad baja al subir la tasa, y en los otros dos no hay una tendencia clara. Como la tasa cambia porque cambian los retardos, el efecto no se puede atribuir solo al tamaño de la ventana.

IV-B. *Tasa de recuperación y rechazo de señales sin codificar*

Para caracterizar la tasa de recuperación en función de la atenuación del eco y del género musical, se evaluaron los cuatro fragmentos de prueba, codificados con bits al azar mediante el prototipo en Python. Con la configuración por defecto ($a = 30\,\%$), la tasa media global alcanza $98.31\,\%$ ($97.57\,\%$ en la clásica y en el *ragtime*, $98.13\,\%$ en el *jazz* y $100.00\,\%$ en electrónica), superando el $90\,\%$. Con $10\,\%$ de atenuación las tres grabaciones reales quedan cerca del $80\,\%$, mientras que la electrónica sintética, de espectro estable, se mantiene sobre el $99\,\%$.

Con $a = 30\,\%$ y otros bits al azar, una ventana mayor reduce la tasa binaria, de 66.82 bit/s con $K = 10$ a 26.73 bit/s con $K = 25$ para $(750, 1500)$ µs, pero la recuperación no crece de forma monótona con K: para ese par va de $95.53\,\%$ con $K = 10$ a $91.69\,\%$ con $K = 15$ y $97.94\,\%$ con $K = 25$.

Finalmente, ante los cuatro archivos originales sin codificar, el filtro de actividad global produce exactamente cero bits emitidos y cero metadatos falsos.

IV-C. *Recuperación de metadatos con votación*

Para medir la votación se pasó la trama por un canal simulado que invierte, borra o inserta bits al azar, cada bit de forma independiente. El mensaje tiene los siete metadatos con textos de prueba (1000 bits) y se repitió hasta llenar 4810 bits, lo que cabe en tres minutos de audio: 4.81 copias. Un metadato cuenta como recuperado si se lee con su texto original. Como se observa en la Tabla I, con $5\,\%$ de bits invertidos la lectura

Tabla I
METADATOS RECUPERADOS, DE SIETE, CON Y SIN VOTACIÓN EN EL CANAL SIMULADO (PROMEDIO DE 20 SEMILLAS).

Canal	Sin votación	Con votación
Sin errores	7.00	7.00
5 % de bits invertidos	0.15	5.15
10 % de bits invertidos	0.00	1.75
15 % de bits invertidos	0.00	0.15
0.5 % de bits borrados	6.70	6.70
0.5 % de bits insertados	6.60	6.60

directa recupera 0.15 de siete en promedio y la votación, 5.15, cerca de los 5.1 que predice la teoría si la copia votada tiene $0.23\,\%$ de bits errados. Con $15\,\%$ ya casi nunca se puede estimar el período, porque las copias dejan de coincidir en el $75\,\%$ de sus bits, y la votación casi no recupera nada. Con bits borrados o insertados la votación no ayuda, porque las copias se alinean enteras.

Para probarlo con audio real, se codificaron tres metadatos en las tres grabaciones seguidas (60 s, 4.77 copias del mensaje). En los seis órdenes posibles de los fragmentos, la votación recuperó los tres metadatos y la lectura directa, uno o dos. Un fragmento de 20 s solo tiene 1.6 copias, menos de las tres que necesita la votación, y en las grabaciones reales recuperó como mucho uno de tres metadatos.

Los valores por defecto (750 µs, 1500 µs, $30\,\%$ y $K = 25$) se obtuvieron a partir de un barrido de 45 combinaciones de retardos y atenuación, evaluando cada una contra 25 tramos de 20 s tomados de cinco grabaciones, distintos de los fragmentos de prueba. De las combinaciones que recuperan al menos el $90\,\%$ de los bits en cada pieza, se eligió la que recupera más metadatos en las grabaciones completas; en caso de empate, se tomó la de mejor calidad. Lo mismo se hizo con el tamaño de la ventana: con K menor a 25, la recuperación baja del $90\,\%$ o la calidad empeora. Con estos valores, el programa final recupera entre el $95.7\,\%$ y el $98.3\,\%$ de los bits en las tres grabaciones. El detalle de este proceso se encuentra en el repositorio.

V. CONCLUSIONES

La calidad perceptual baja de forma sostenida con la amplitud del eco, y el *jazz* es el género más sensible; con los valores por defecto la nota PESQ es de 3.80 a 4.15. La SNR queda fijada por la atenuación, $-20\log_{10} a$, y no sirve para comparar géneros.

La calidad y la recuperación se oponen (correlación de -0.76). La relación entre la tasa de transferencia y la calidad depende del género: en el *jazz* la calidad baja al subir la tasa, y en la clásica y el *ragtime* no hay una tendencia clara.

La tasa de recuperación crece con la amplitud del eco y, con la atenuación por defecto, supera el $90\,\%$ en los cuatro géneros. El factor de ventana K cambia la tasa de transferencia, pero su efecto sobre la recuperación no es monótono.

Con atenuaciones bajas, las grabaciones reales de los tres géneros recuperan menos que la electrónica sintética: con $10\,\%$, cerca del $80\,\%$ frente a más del $99\,\%$.

En los cuatro archivos sin codificar probados, el filtro de actividad no dejó pasar ningún bit, así que no se reportó ningún metadato falso.

La votación entre las copias repetidas del mensaje lleva la recuperación de metadatos con $5\,\%$ de bits errados de 0.15 a 5.15 de siete, como predice la teoría con errores independientes, y en el audio real probado fue necesaria para recuperar todos los metadatos. Dicho eso, tiene limitaciones que se deben considerar: no corrige bits perdidos o agregados, deja de funcionar cerca del $15\,\%$ de bits errados y necesita al menos tres copias.

Los valores por defecto del sistema (750 µs, 1500 µs, $30\,\%$ y $K = 25$) son, entre las combinaciones que recuperan al menos el $90\,\%$ de los bits, los que más metadatos recuperan. Con ellos, el sistema cumple ese mínimo en todos los fragmentos de prueba, donde recupera al menos el $95.7\,\%$ de los bits. Cabe notar que estos resultados se limitan a una grabación por género, al canal izquierdo y a archivos que no se modifican después de codificados.

Como trabajo futuro se recomienda adaptar la amplitud del eco a cada ventana, usando más eco donde la música lo enmascara y menos donde se oiría, para mejorar a la vez la calidad y la recuperación; evaluar el sistema con archivos comprimidos, con ruido o remuestreados; reemplazar la repetición por un código corrector de errores con menos redundancia, que también funcione en audios cortos; y medir la calidad con una métrica diseñada para audio, como la evaluación perceptual de la calidad de audio (PEAQ) [8], en lugar de PESQ, pensada para voz.

REFERENCIAS

[1] P. Dutta, D. Bhattacharyya, y T. Kim, "Data hiding in audio signal: A review," *International Journal of Database Theory and Application*, vol. 2, 2009.

[2] N. Kaur y S. Behal, "Audio steganography techniques – a survey," *International Journal of Engineering Research and Applications*, vol. 4, pp. 94–100, 2014.

[3] D. Gruhl, A. Lu, y W. Bender, "Echo hiding," en *Information Hiding*, ser. Lecture Notes in Computer Science. Springer, 1996, pp. 295–315. [En línea]. Disponible: https://doi.org/10.1007/3-540-61996-8_48

[4] F. Yergeau, "UTF-8, a transformation format of ISO 10646," RFC 3629, https://www.rfc-editor.org/rfc/rfc3629, Nov. 2003.

[5] G. Cook, "Catalogue of parametrised CRC algorithms with 16 bits," https://reveng.sourceforge.io/crc-catalogue/16.htm, entrada CRC-16/IBM-3740.

[6] ITU-T, "P.862: Perceptual evaluation of speech quality (PESQ): An objective method for end-to-end speech quality assessment of narrow-band telephone networks and speech codecs," https://www.itu.int/rec/T-REC-P.862/en, 2018.

[7] ——, "P.862.2: Wideband extension to recommendation P.862 for the assessment of wideband telephone networks and speech codecs," https://www.itu.int/rec/T-REC-P.862.2-200711-W/en, Nov. 2007.

[8] ITU-R, "BS.1387-2: Method for objective measurements of perceived audio quality," https://www.itu.int/rec/R-REC-BS.1387/en, may. 2023.