Esteganografía de metadatos en audio mediante enmascaramiento con eco

Marco Zolla Salazar, Marcelo Mata Solano y Diego Martínez

***Abstract*—TODO.**

***Palabras clave*—TODO.**

I. Introducción

La esteganografía en señales de audio consiste en ocultar información digital dentro de una señal portadora acústica sin alterar de manera perceptible su reproducción. A diferencia del cifrado criptográfico, cuyo propósito es volver ininteligible un mensaje, la esteganografía busca que la existencia misma de los datos incrustados pase inadvertida para el sistema auditivo humano, lo que resulta de gran utilidad en el almacenamiento de metadatos de canciones, el control de derechos de autor y la autenticación de grabaciones [1], [2].

Entre las técnicas clásicas reportadas en el estado del arte destacan la sustitución del bit menos significativo, la codificación de fase, el espectro disperso y el enmascaramiento con eco [1], [2]. La sustitución de bits ofrece alta capacidad de transmisión, pero presenta baja robustez ante perturbaciones de cuantización. Por su parte, el enmascaramiento con eco, introducido originalmente por Gruhl, Lu y Bender [3], aprovecha la propiedad psicoacústica según la cual una réplica atenuada con un retardo del orden de un milisegundo no se percibe como un eco separado, sino como una ligera resonancia espectral enmascarada por la señal principal. De este modo, el codificador representa cada bit mediante un sistema lineal e invariante en el tiempo (LTI) con un retardo específico, mientras que el decodificador identifica dicho retardo mediante el análisis de la autocorrelación del cepstro [3]. Trabajos posteriores, como el de Korzhik [4], han analizado las condiciones espectrales y el diseño de secuencias que minimizan la probabilidad de error de bit durante la extracción.

El resto de este artículo se organiza de la siguiente manera. En la Sección II se desarrolla el marco teórico del enmascaramiento con eco mediante sistemas LTI y la formulación de la autocorrelación del cepstro en el dominio espectral. En la Sección III se detalla la solución propuesta para el codificador, el decodificador y la trama de metadatos. En la Sección IV se presentan y discuten los resultados experimentales de calidad perceptual, tasa de recuperación por género musical, rechazo de archivos sin codificar y sus correlaciones. Finalmente, en la Sección V se exponen las conclusiones y las recomendaciones para trabajos futuros.

II. Marco teórico

TODO.

Maestría en Electrónica, Instituto Tecnológico de Costa Rica.

II-A. Cepstro y autocorrelación espectral

Cuando una ventana de audio $v_k(n)$ atraviesa el filtro de eco $h_b(n) = \delta(n) + a_b\delta(n - d_b)$ asociado al bit $b \in \{0, 1\}$, su transformada de Fourier de tiempo discreto satisface $Y_k(\omega) = V_k(\omega)\left(1 + a_b e^{-j\omega d_b}\right)$. Para separar multiplicativamente la respuesta del eco respecto a la señal portadora, se emplea el cepstro $c(n)$, definido en la Ecuación (1) a partir de la transformada de Fourier $\mathcal{F}$ y su inversa $\mathcal{F}^{-1}$ [3]:

$$c(n) = \mathcal{F}^{-1}\left\{\ln\left(\mathcal{F}\{y_k(n)\}\right)\right\}. \tag{1}$$

Para $a_b < 1$, la expansión en serie de Taylor $\ln(1 + a_b e^{-j\omega d_b}) = \sum_{m=1}^{\infty} \frac{(-1)^{m+1}}{m} a_b^m e^{-j\omega m d_b}$ muestra que el eco induce en el dominio de la quefrencia n un tren de impulsos ubicado en los múltiplos del retardo d_b, donde el término dominante en $n = d_b$ posee amplitud proporcional a a_b.

Con el propósito de reforzar dicho impulso frente a las variaciones propias de la señal musical, Gruhl *et al.* [3] proponen evaluar la convolución del cepstro consigo mismo. Aplicando el teorema de convolución, la autocorrelación del cepstro $R_{cc}(n)$ se calcula directamente en el dominio espectral según la Ecuación (2):

$$R_{cc}(n) = c(n) * c(n) = \mathcal{F}^{-1}\left\{\left(\ln\left|\mathcal{F}\{\hat{v}_k(n)\}\right|\right)^2\right\}. \tag{2}$$

El uso del logaritmo de la magnitud espectral $|\mathcal{F}\{\hat{v}_k(n)\}|$ en la Ecuación (2) evita la discontinuidad de salto de $\pm\pi$ propia del valor principal de la fase compleja, la cual introduciría ruido de banda ancha al elevar el espectro logarítmico al cuadrado. Asimismo, dado que escalar la señal por un factor G suma una constante $\ln G$ al componente de quefrencia cero $c(0)$ y modifica el término cruzado $2c(0)c(d_b)$ de $R_{cc}(d_b)$, es indispensable normalizar previamente cada ventana $\hat{v}_k(n)$ a una raíz cuadrática media (RMS) de referencia constante $\mathrm{RMS}_{\mathrm{ref}}$, garantizando así que el clasificador sea invariante ante pasajes musicales fuertes o débiles.

III. Solución propuesta

III-A. Codificador de eco

El codificador inserta informacion binaria en una senal de audio mediante la suma de ecos de baja amplitud. Se asigna un retardo diferente a cada simbolo: D_0 para el bit cero y D_1 para el bit uno. Para una ventana que contiene el bit b, el eco agregado corresponde a una copia atenuada y desplazada de sus muestras:

$$e_b[n] = \begin{cases} \alpha_b x[n - D_b], & n - D_b \text{ pertenece a la ventana,} \\ 0, & \text{en otro caso.} \end{cases} \tag{3}$$

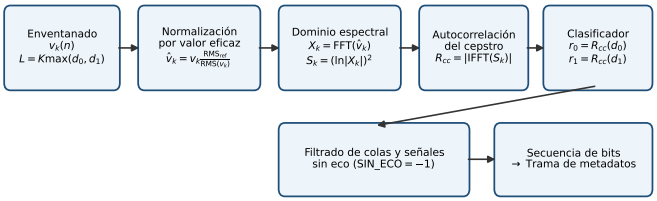


Figura 1. Diagrama de bloques del subsistema decodificador implementado.

La senal resultante se obtiene sumando el audio original y las contribuciones de todas las ventanas: $y[n] = x[n] + \sum_b e_b[n]$, donde la suma se entiende sobre las ventanas que contienen los bits.

Se desarrollo un prototipo en Python y una implementacion en C++17. El programa lee audio WAV estereo PCM16, permite elegir el canal de insercion, configurar los retardos y las atenuaciones, e introducir un mensaje binario. Las contribuciones desplazadas se acumulan mediante Overlap-Add y el canal no seleccionado conserva sus muestras originales. Al escribir el WAV se aplica saturacion al intervalo PCM16 y truncamiento hacia cero.

En las pruebas se utilizo una frecuencia de muestreo de 44.1 kHz, retardos de 1 y 2 ms (respectivamente 44 y 88 muestras), y una longitud de ventana $N = K\,\mathrm{máx}(D_0, D_1)$ con $K = 25$; por tanto, $N = 2200$ muestras (49.89 ms). Este valor de K es provisional hasta comprobar el desempeno del decodificador. Para el mensaje 101101 y una atenuacion del $20\,\%$ en ambos retardos, las implementaciones Python y C++ produjeron archivos con cero diferencias entre las muestras PCM16 del canal codificado.

Para la prueba de integracion con el decodificador se utilizo una configuracion diferente: retardos de 44 y 66 muestras, atenuacion del $30\,\%$ y ventanas de 1650 muestras. En esta configuracion se codifico una trama de metadatos repetida hasta ocupar las ventanas disponibles. Los resultados de calidad y correlacion presentados corresponden a los experimentos iniciales y no a esta configuracion de integracion.

III-B. Subsistema decodificador

El subsistema decodificador recibe el canal seleccionado del archivo en formato de modulación por impulsos codificados (PCM) de $16\,\mathrm{bits}$ a $f_s = 44.1\,\mathrm{kHz}$ y los retardos configurados t_0 y t_1 en microsegundos, los cuales se convierten a muestras enteras mediante $d_b = \lfloor (t_b f_s + 5\times10^5)/10^6 \rfloor$. A partir del mayor retardo se fija la longitud de ventana $L = K\,\mathrm{máx}(d_0, d_1)$ con $K = 25$, segmentando la señal en $N_v = \lfloor N_{\mathrm{muestras}}/L \rfloor$ ventanas contiguas $v_k(n)$. La arquitectura completa del módulo se ilustra en la Figura 1.

En cada ventana $v_k(n)$ se calcula primero su valor eficaz $\mathrm{RMS}(v_k) = \sqrt{\frac{1}{L}\sum_{n=0}^{L-1} v_k^2(n)}$. Si $\mathrm{RMS}(v_k) \le 10^{-5}$, la ventana se declara silenciosa y se etiqueta inmediatamente como carente de eco ($\mathrm{SIN_ECO} = -1$). En caso contrario, se normaliza mediante $\hat{v}_k(n) = v_k(n)\,\mathrm{RMS}_{\mathrm{ref}}/\mathrm{RMS}(v_k)$ con $\mathrm{RMS}_{\mathrm{ref}} = 1000$, eliminando cualquier dependencia respecto a la amplitud de entrada. Posteriormente, $\hat{v}_k(n)$ se rellena con ceros hasta la siguiente potencia de dos $N_{\mathrm{FFT}} = 2^{\lceil \log_2 L \rceil}$ y se evalúa la transformada rápida de Fourier (FFT) propia de base dos. Para prevenir singularidades logarítmicas en frecuencias nulas, cada magnitud espectral se acota inferiormente por $\epsilon = 10^{-12}$ antes de calcular $S_k(m) = (\ln \mathrm{máx}(|X_k(m)|, \epsilon))^2$ y aplicar la transformada inversa rápida de Fourier (IFFT) que entrega $|R_{cc}(n)|$.

Finalmente, el clasificador evalúa las magnitudes $r_0 = |R_{cc}(d_0)|$ y $r_1 = |R_{cc}(d_1)|$. Si $\mathrm{máx}(r_0, r_1) < U_{\mathrm{eco}}$ con umbral $U_{\mathrm{eco}} = 0.70$, o si $r_0 = r_1$, la ventana individual se clasifica como SIN_ECO; de lo contrario, se asigna el bit 0 cuando $r_0 > r_1$ y el bit 1 cuando $r_1 > r_0$. A nivel de señal completa, si menos del $25\,\%$ de las ventanas no silenciosas superan U_{eco}, el archivo se reconoce como no codificado y se devuelve una secuencia vacía; en archivos codificados, se recortan las colas finales sin eco y se entregan los bits al intérprete de trama. TODO.

IV. Resultados

IV-A. Calidad de la señal codificada

Se comparó el audio original con el audio codificado para evaluar el efecto de la atenuación del eco. Se utilizó un fragmento musical estéreo en PCM de 16 bits, con frecuencia de muestreo de 44.1 kHz, y se insertó el mensaje 101101 en el canal izquierdo. Los retardos fueron de 44 y 88 muestras y la ventana tuvo una longitud de 2200 muestras.

Tabla I
Resultados de calidad para diferentes atenuaciones

Atenuación	MSE	SNR (dB)
$5\,\%$	6.5864×10^{-7}	42.581
$10\,\%$	2.6333×10^{-6}	36.563
$15\,\%$	5.9242×10^{-6}	33.041
$20\,\%$	1.0531×10^{-5}	30.543
$25\,\%$	1.6454×10^{-5}	28.605

Se observa que, al aumentar la atenuación, crece el error cuadrático medio (MSE) y disminuye la relación señal-ruido (SNR). Con una atenuación del $20\,\%$, el SNR fue de 30.543 dB. La comparación entre Python y C++17 produjo cero diferencias entre las muestras PCM16 para esta configuración.

También se obtuvo un valor exploratorio PESQ-WB de 4.6002 tras remuestrear las señales a 16 kHz. Esta métrica se diseñó para voz, por lo que no constituye una evaluación perceptual validada para el fragmento musical utilizado [5].

Los indicadores MSE y SNR se calcularon sobre la grabación completa. Como solamente se insertaron seis bits, gran parte del audio permaneció sin modificar; estos valores no representan necesariamente la calidad al ocupar todas las ventanas disponibles. Quedan pendientes las pruebas con otros géneros musicales y diferentes cargas de información.

IV-B. Tasa de recuperación y rechazo de señales sin codificar

La discriminación entre ventanas codificadas y sin codificar mediante $|R_{cc}(n)|$ se ejemplifica en la Figura 2. Se observa que un bit 0 induce un impulso pronunciado en $d_0 = 44$ muestras ($1000\,\mu\mathrm{s}$) que supera ampliamente el umbral $U_{\mathrm{eco}} = 0.70$, mientras que un bit 1 concentra el pico en $d_1 = 66$ muestras

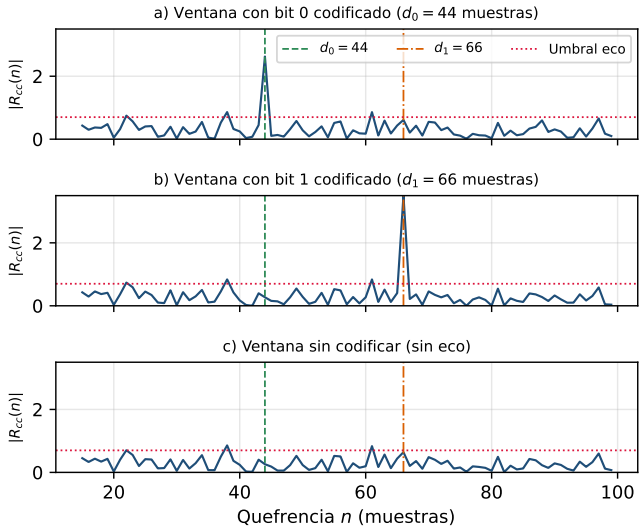


Figura 2. Magnitud de la autocorrelación del cepstro $|R_{cc}(n)|$ para una ventana con bit 0 ($d_0 = 44$), bit 1 ($d_1 = 66$) y sin codificar ($a = 30\,\%$, $K = 25$).

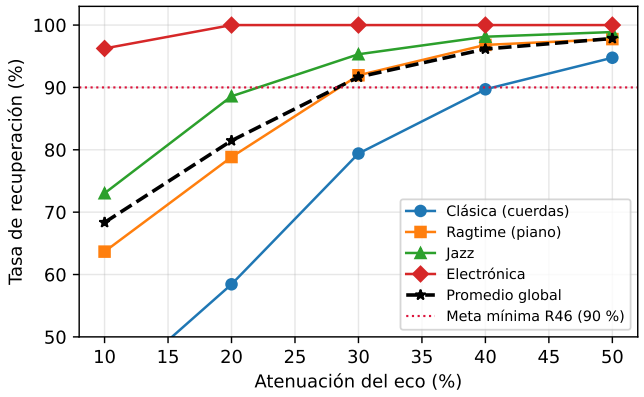


Figura 3. Tasa de recuperación de bits frente a la atenuación del eco para cuatro géneros musicales y su promedio global ($t_0 = 1000\,\mu$s, $t_1 = 1500\,\mu$s, $K = 25$).

(1500 µs); por el contrario, la ventana sin eco permanece por debajo de U_{eco} en ambos retardos.

Para caracterizar la tasa de recuperación en función de la atenuación del eco y del género musical, se evaluaron fragmentos de 20 s (534 ventanas con $K = 25$, $d_0 = 44$ y $d_1 = 66$) de cuatro géneros: música clásica de cuerdas, *ragtime* en piano acústico, *jazz* y música electrónica. La evolución de la tasa de acierto de bits se presenta en la Figura 3. Con la configuración por defecto ($a = 30\,\%$), la tasa media global alcanza $91.67\,\%$ ($91.95\,\%$ en *ragtime*, $95.32\,\%$ en *jazz* y $100.00\,\%$ en electrónica), superando la meta del $90\,\%$. La pieza clásica de violín presenta una tasa menor en bajas atenuaciones ($79.40\,\%$ a $30\,\%$ y $94.76\,\%$ a $50\,\%$), lo cual se explica teóricamente porque las notas sostenidas del violín en mi mayor poseen periodos fundamentales cercanos a $f_s/659.25\,\text{Hz} \approx 66.9$ muestras, cuyos armónicos en quefrencia interfieren con el retardo $d_1 = 66$.

Tabla II
TASA DE TRANSFERENCIA Y RECUPERACIÓN MEDIA ($a = 30\,\%$) SEGÚN LOS RETARDOS Y EL FACTOR DE VENTANA K.

(t_0, t_1) (µs)	K	L (muestras)	Tasa (bps)	Recuperación (%)
$(500, 750)$	20	660	66.82	90.46
$(500, 750)$	25	825	53.45	91.77
$(750, 1000)$	25	1100	40.09	91.95
$(1000, 1500)$	10	660	66.82	86.04
$(1000, 1500)$	15	990	44.55	86.69
$(1000, 1500)$	20	1320	33.41	90.57
$(1000, 1500)$	25	1650	26.73	93.07
$(1500, 2000)$	25	2200	20.05	92.75

Tabla III
DESEMPEÑO DEL DECODIFICADOR ANTE AUDIO SIN CODIFICAR.

Género	Sin eco (%)	Media $\max(r_0, r_1)$	Bits	Falsos
Clásica	82.77	0.497	0	0
Ragtime	85.58	0.430	0	0
Jazz	92.88	0.345	0	0
Electrónica	94.01	0.351	0	0

El efecto del factor de longitud de ventana K y de los retardos (t_0, t_1) sobre la tasa de transferencia y la recuperación media con $a = 30\,\%$ se resume en la Tabla II. Al incrementar K de 10 a 25, la tasa media sube de $86.04\,\%$ a $93.07\,\%$ para $(1000, 1500)\,\mu$s, debido a que una ventana mayor reduce la varianza del estimador espectral y la fracción de muestras afectadas por la cola de solapamiento de la ventana previa, a cambio de reducir la tasa binaria de $66.82\,\text{bps}$ a $26.73\,\text{bps}$.

Finalmente, en la Tabla III se reporta el comportamiento del decodificador ante los cuatro archivos originales sin codificar. Entre el $82.77\,\%$ y el $94.01\,\%$ de las ventanas individuales se descartan directamente como SIN_ECO, con valores medios de $\max(r_0, r_1)$ entre 0.345 y 0.497 (inferiores a $U_{\text{eco}} = 0.70$). En los cuatro géneros, el filtro de actividad global y la verificación de redundancia cíclica (CRC) de la trama producen exactamente cero bits emitidos y cero metadatos falsos.

IV-C. Verificación de los retardos mediante correlación

Para comprobar la inserción de los ecos, se restó el audio original del audio codificado y se calculó la correlación cruzada entre ese residuo y la señal original, por ventanas de 2200 muestras. Se examinaron retardos positivos de 1 a 150 muestras.

Tabla IV
RETARDOS ESPERADOS Y DETECTADOS

Ventana	Bit	Esperado	Detectado
1	1	88	88
2	0	44	44
3	1	88	88
4	1	88	88
5	0	44	44
6	1	88	88

Se identificó el retardo esperado en las seis ventanas del mensaje 101101. Este resultado comprueba la presencia de los ecos en la prueba realizada, pero no equivale a una recuperación independiente del mensaje: el procedimiento utiliza

el audio original como referencia. La relación entre tasa de transferencia, calidad y recuperación de bits requiere pruebas adicionales con el decodificador.

V. Conclusiones

En el fragmento evaluado, el aumento de la atenuación del eco produjo una disminución del SNR, de 42.581 dB con un $5\,\%$ de atenuación a 28.605 dB con un $25\,\%$. Por tanto, existe un compromiso entre la intensidad del eco insertado y la alteración de la señal. La selección de una atenuación adecuada requiere comprobar también la recuperación de los bits. Los resultados actuales corresponden a un único fragmento musical y a un mensaje de seis bits; no permiten generalizar el comportamiento a otros géneros ni a una ocupación completa de las ventanas. La evaluación de la autocorrelación del cepstro en el dominio espectral a partir del logaritmo de la magnitud espectral y la normalización por valor eficaz elimina la dependencia de escala de la señal portadora y las discontinuidades de fase, permitiendo distinguir de forma robusta los retardos d_0 y d_1 frente al piso cepstral de ventanas sin eco.

La tasa de recuperación crece monótonamente con la amplitud del eco y con el factor de tamaño de ventana K; la configuración por defecto ($t_0 = 1000\,\mu\text{s}$, $t_1 = 1500\,\mu\text{s}$, $a = 30\,\%$ y $K = 25$) alcanza una recuperación media de hasta $93.07\,\%$ a una tasa binaria de $26.73\,\text{bps}$, cumpliendo el requerimiento mínimo del $90\,\%$.

El contenido espectral del género musical incide directamente en el desempeño del decodificador: las señales con espectro denso o percusivo (*ragtime*, *jazz* y electrónica) superan el $91.9\,\%$ de recuperación con $a = 30\,\%$, mientras que las cuerdas frotadas sostenidas presentan mayor interferencia cepstral cuando sus periodos armónicos coinciden con los retardos de codificación.

El criterio de umbral sobre $\max(|R_{cc}(d_0)|, |R_{cc}(d_1)|)$ combinado con la validación de actividad mínima por señal permite identificar entre el $82.77\,\%$ y el $94.01\,\%$ de las ventanas individuales sin eco y garantiza una tasa de falsos positivos nula (cero bits y cero metadatos espurios) al procesar archivos de audio no codificados. La correlación cruzada permitió identificar los retardos de 44 y 88 muestras en las seis ventanas analizadas. Esto respalda el funcionamiento de la inserción de ecos en el codificador para la configuración probada. No obstante, la verificación utilizó el audio original como referencia y, por ello, no demuestra todavía la recuperación del mensaje mediante el decodificador ni su desempeño frente a distintas tasas de transferencia. TODO.

Referencias

[1] P. Dutta, D. Bhattacharyya, and T. Kim, "Data hiding in audio signal: A review," *International Journal of Database Theory and Application*, vol. 2, 2009. [Online]. Available: http://www.sersc.org/journals/IJDTA/vol2_no2/1.pdf

[2] N. Kaur and S. Behal, "Audio steganography techniques – a survey," *International Journal of Engineering Research and Applications*, vol. 4, pp. 94–100, 2014. [Online]. Available: http://www.ijera.com/papers/Vol4_issue6/Version%205/P0460594100.pdf

[3] D. Gruhl, A. Lu, and W. Bender, "Echo hiding," Massachusetts Institute of Technology Media Laboratory, Tech. Rep. [Online]. Available: https://pdfs.semanticscholar.org/b964/4dbf393117b4c4bb91122cf7b08f71b71fbd.pdf

[4] V. Korzhik, "Audio watermarking based on echo hiding with zero error probability," *International Journal of Computer Science and Applications*, vol. 10, pp. 1–10, 2013. [Online]. Available: http://www.tmrfindia.org/ijcsa/v10i11.pdf

[5] ITU Radiocommunication Assembly, "P.862: Perceptual evaluation of speech quality (PESQ): An objective method for end-to-end speech quality assessment of narrow-band telephone networks and speech codecs," https://www.itu.int/rec/T-REC-P.862/en, 2018.